



中国海洋大学
OCEAN UNIVERSITY OF CHINA

教育部直属“985工程”“211工程”国家重点建设大学

海纳百川 取则行远

基于PCA的卷积神经网络



董军宇
中国海洋大学计算机系
2015年6月6日

PCN-基于PCA的卷积神经网络 (PCA-based Convolutional Networks)

- 相关工作概况
- 卷积神经网络 (CNN)
- PCANet – 基于PCA的网络
- PCN的基本结构
- 部分实验
- 总结

PCN-基于PCA的卷积神经网络



- 对智能化的追求
- 对海量数据的分析和挖掘




机器学习的目的就是使
机器能够像人类大脑一
样思考



- 步态识别
- 人脸识别
- 天气预测
- 自动驾驶
- 物体识别
- 图像翻译
- 语音识别

• • •

PCN-基于PCA的卷积神经网络



深度学习&机器学习

Deep learning, Review, in
Nature, May 2015



[LeCun](#), [Bengio](#) & [Hinton](#)



主
的
功
，


PCN-基于PCA的卷积神经网络

➤ 深度学习的一般模式



PCN-基于PCA的卷积神经网络


➤ 深度信念网络



- 通过对比散度训练每一层的RBM
- 使用wake-sleep (up-down) 算法对网络进行微调

PCN-基于PCA的卷积神经网络

➤ 自动编码器



将多个自动编码器级联起来就是一个深度网络，如果对隐层节点施加稀疏性约束就是稀疏自动编码器

PCN-基于PCA的卷积神经网络

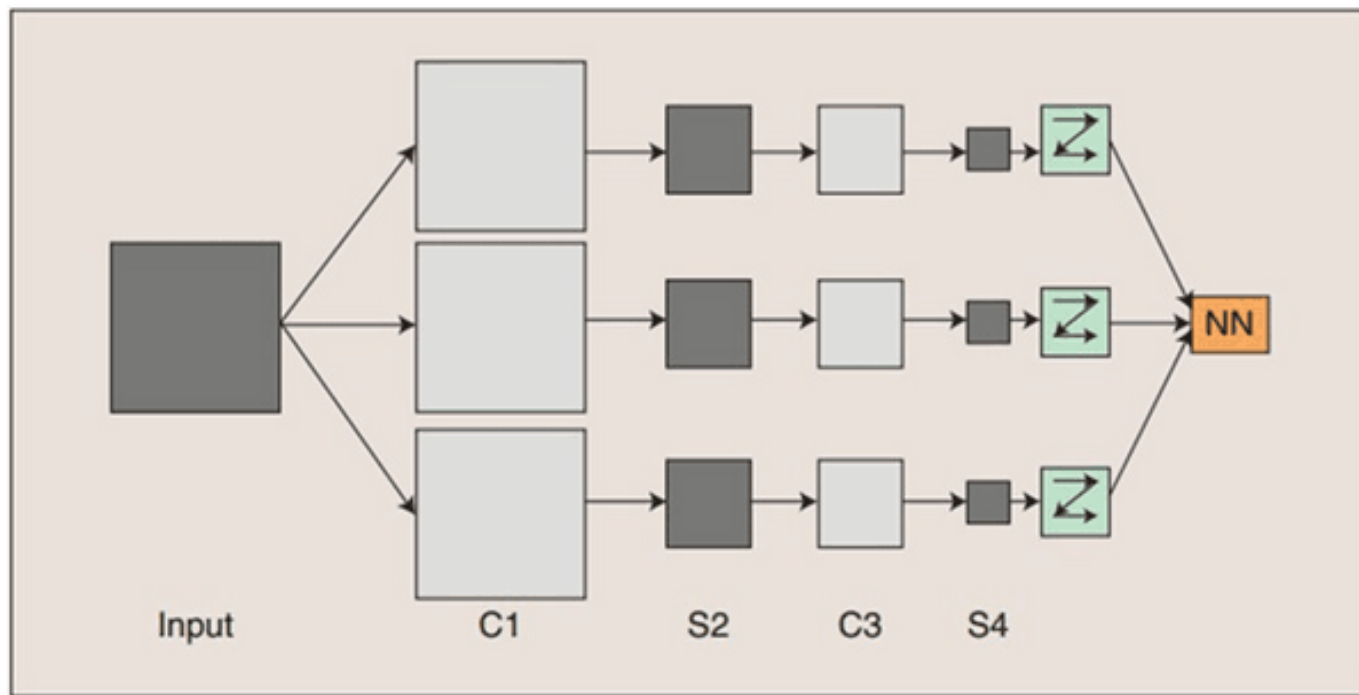
- 采用全链接的方法导致网络参数急剧增多
- 不符合人类视觉感知的生物学原理

PCN-基于PCA的卷积神经网络 (PCA-based Convolutional Networks)

- 相关工作概况
- 卷积神经网络 (CNN)
- PCANet
- PCN的基本结构
- 部分实验
- 总结

卷积神经网络


➤ 卷积神经网络（Convolutional Network）



- 多层的神经网络，每层由多个二维平面组成，每个平面由多个独立神经元组成
- 输入图像和三个可训练的滤波器和可加偏置进行卷积并通过激活函数
- C层-特征提取层；每个神经元的输入与前一层的局部感受野相连，提取局部特征
- S层-特征池化层

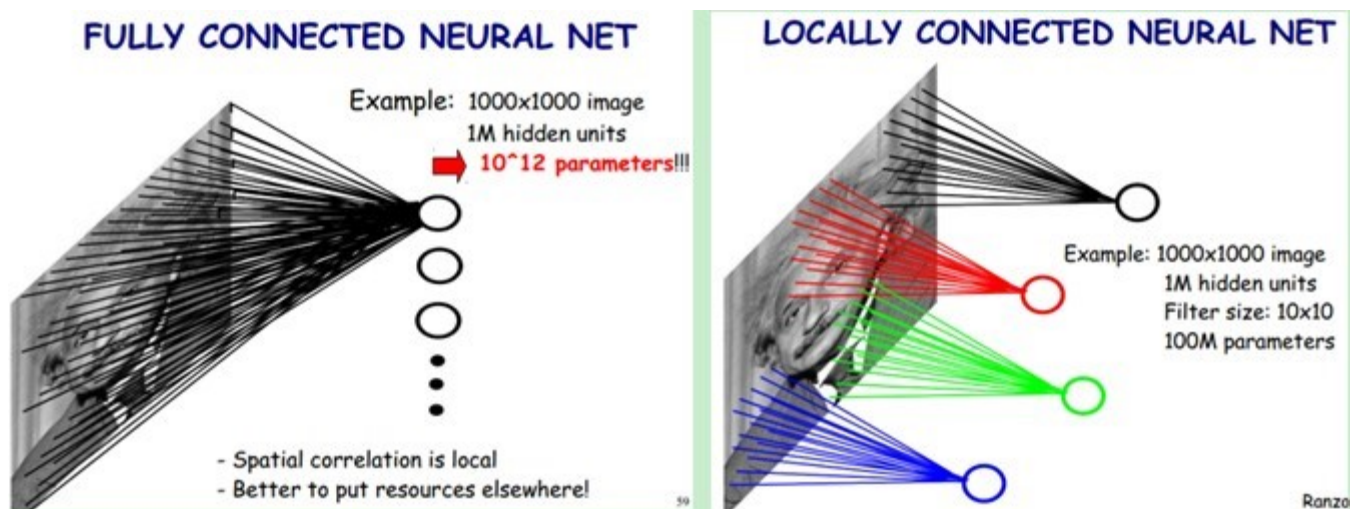
卷积神经网络

➤ 卷积神经网络的结构



- 归一化：去均值；局部对比度归一化
- 滤波器组：dimension expansion, projection on overcomplete basis
- 非线性：Rectification, Tanh, Sigmoid...
- 池化：Average, L1, L2, Max

卷积神经网络



通过局部感受野和权值共享显著减少参数个数

卷积神经网络

➤ 优化加速

深度网络的结构较为复杂，需要经过复杂的超参数选择和漫长的训练过程

高效程序设计语言和GPU加速

结构复杂，需要众多的硬件和软件支持，并附带较为复杂的环境配置

网络本身的时间复杂度和空间复杂度并没有减少

在软硬件条件比较简单的条件下也能达到与传统深度网络相匹配的效果

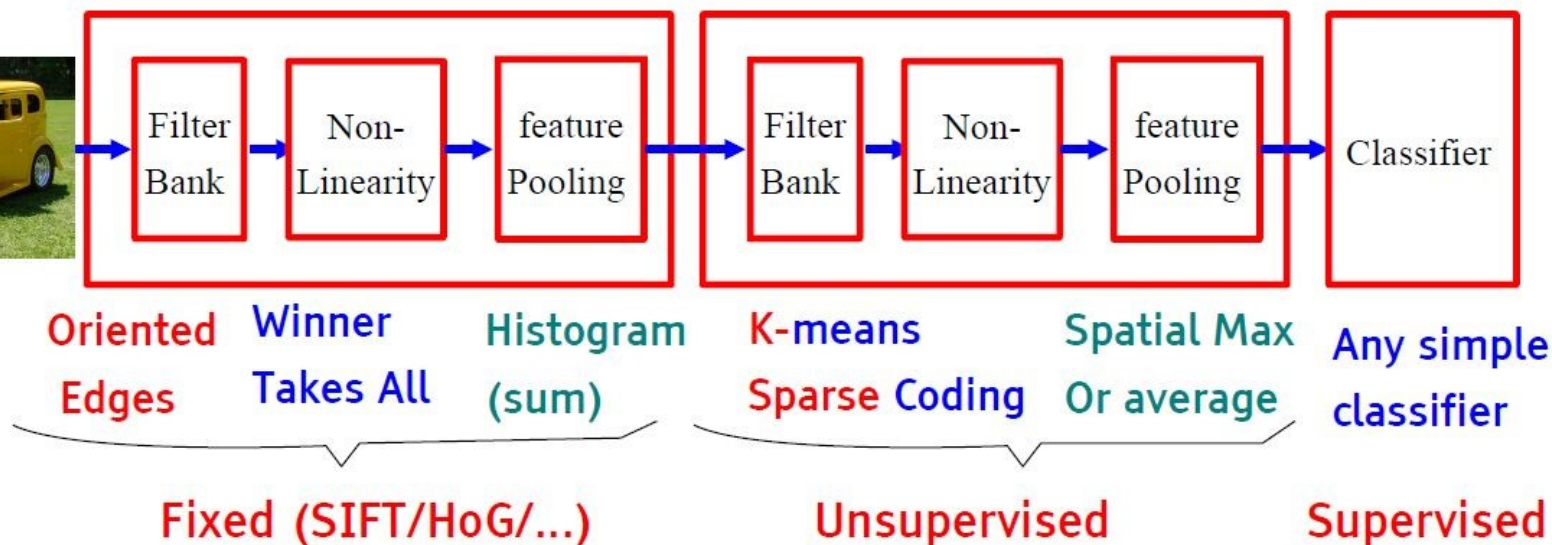


目的

PCN-基于PCA的卷积神经网络 (PCA-based Convolutional Networks)

- 相关工作概况
- 卷积神经网络 (CNN)
- **PCANet**
- PCN的基本结构
- 部分实验
- 总结

PCANet – 传统上的类似做法



■ Fixed Features + unsupervised mid-level features + simple classifier

▶ SIFT + Vector Quantization + Pyramid pooling + SVM

• [Lazebnik et al. CVPR 2006]

▶ SIFT + Local Sparse Coding Macrofeatures + Pyramid pooling + SVM

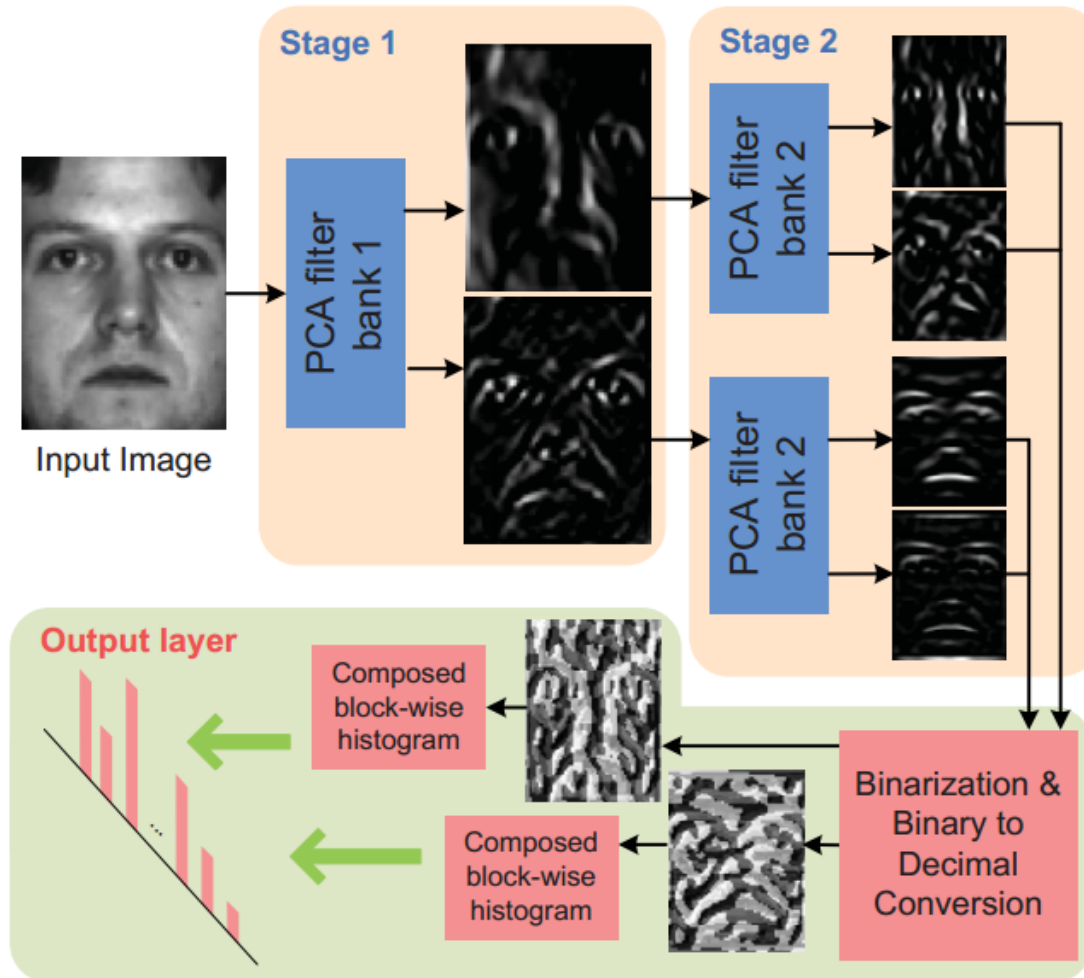
• [Boureau et al. ICCV 2011]

▶ SIFT + Fisher Vectors + Deformable Parts Pooling + SVM

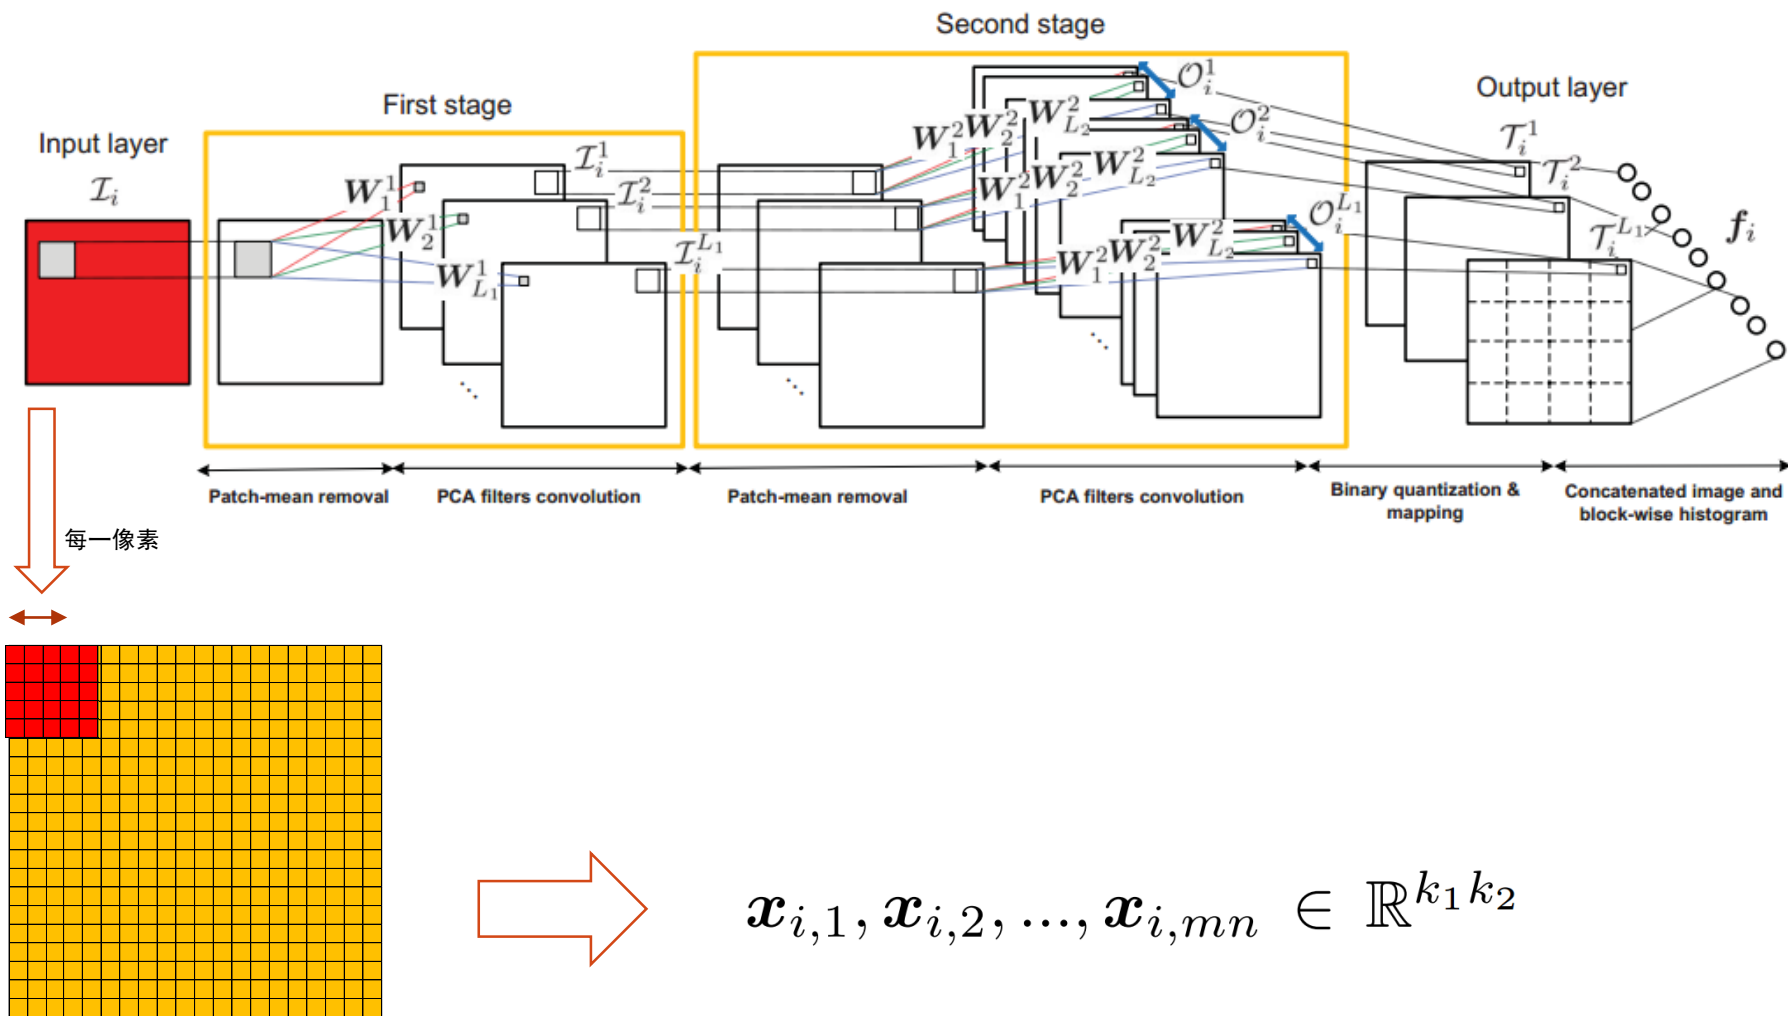
• [Perronin et al. 2012]

PCANet

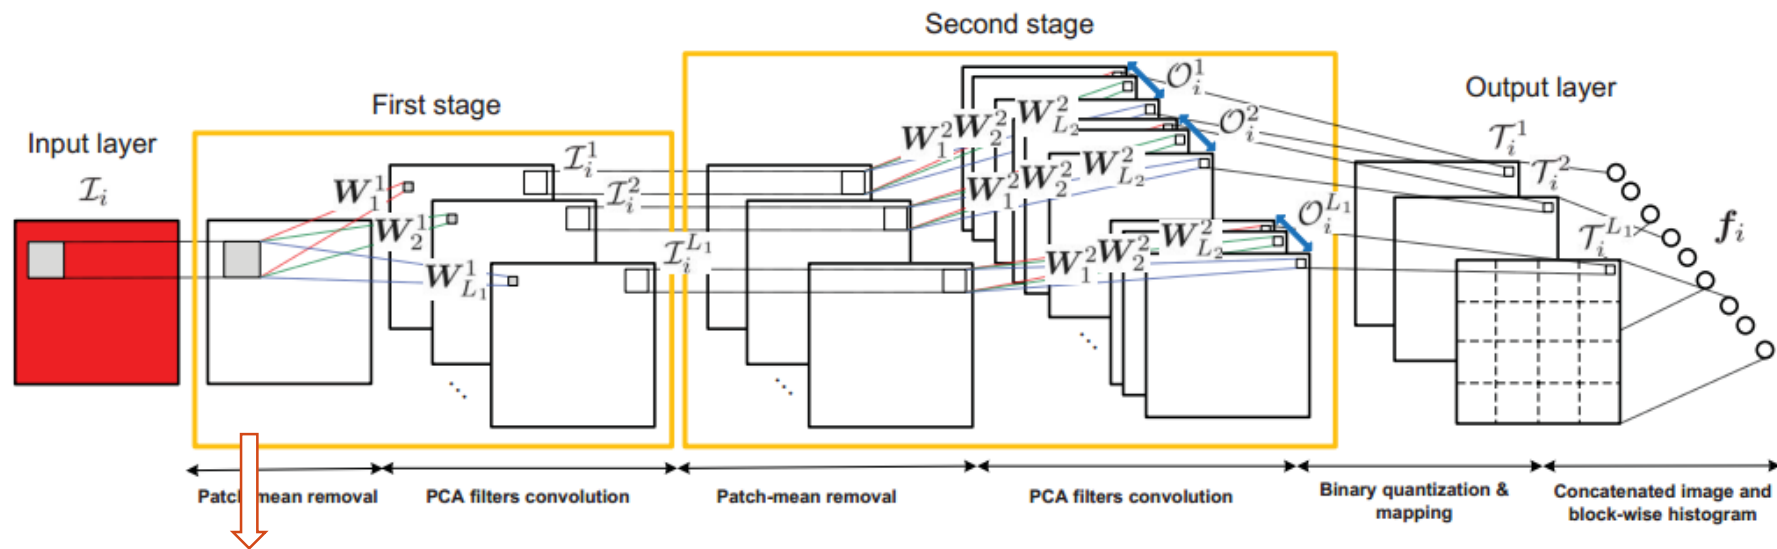
➤ PCANet 的整体结构



PCN-基于PCA的卷积神经网络



PCN-基于PCA的卷积神经网络



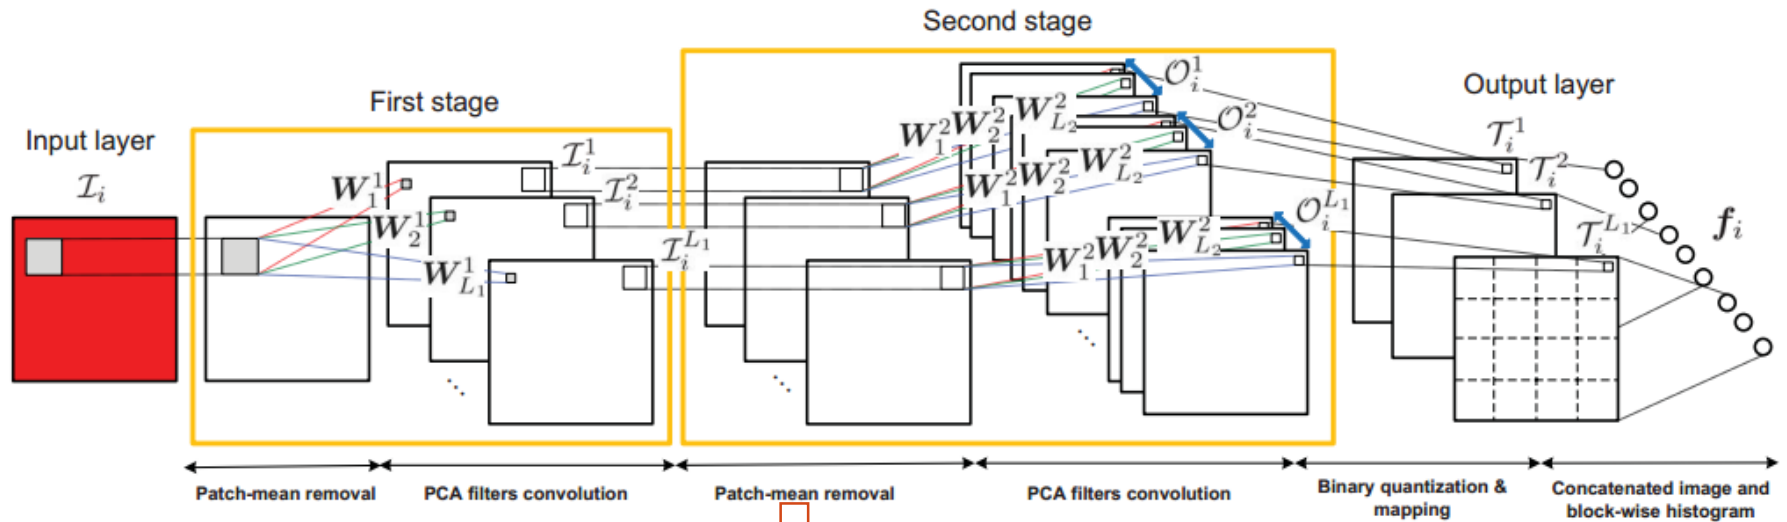
$$\bar{X}_i = [\bar{x}_{i,1}, \bar{x}_{i,2}, \dots, \bar{x}_{i,mn}]$$

$$X = [\bar{X}_1, \bar{X}_2, \dots, \bar{X}_N]$$

PCA分解

$$W_l^1 \doteq \text{mat}_{k_1, k_2}(\mathbf{q}_l(\mathbf{X}\mathbf{X}^T)) \in \mathbb{R}^{k_1 \times k_2}, \quad l = 1, 2, \dots, L_1$$

PCN-基于PCA的卷积神经网络



L1个滤波器

$$\mathcal{I}_i^l \doteq \mathcal{I}_i * \mathbf{W}_l^1, \quad i = 1, 2, \dots, N$$

$$\bar{\mathbf{Y}}_i^l = [\bar{\mathbf{y}}_{i,l,1}, \bar{\mathbf{y}}_{i,l,2}, \dots, \bar{\mathbf{y}}_{i,l,mn}] \in \mathbb{R}^{k_1 k_2 \times mn}$$

$$\mathbf{Y} = [\mathbf{Y}^1, \mathbf{Y}^2, \dots, \mathbf{Y}^{L_1}] \in \mathbb{R}^{k_1 k_2 \times L_1 N mn}$$

$$\mathbf{W}_\ell^2 \doteq \text{mat}_{k_1, k_2}(\mathbf{q}_\ell(\mathbf{Y}\mathbf{Y}^T)) \in \mathbb{R}^{k_1 \times k_2}, \quad \ell = 1, 2, \dots, L_2$$

➤ PCANet的几点不足

- 连续采样增加了图像块的数量，在高分辨率图像上没有必要且增加了算法的空间复杂度
- 缺少特征池化的过程，导致最后输出的特征维数过大
- 高层求解滤波器简单地提取所有有输入特征图的图像块，然后堆叠在一起进行PCA分解
- 没有体现高层特征对低层特征的组合，学习出的滤波器对所有输入特征图是对称的

PCN-基于PCA的卷积神经网络 (PCA-based Convolutional Networks)

- 相关工作概况
- 卷积神经网络 (CNN)
- PCANet的提出
- **PCN的基本结构**
- 部分实验
- 总结

➤ PCN的基本思想

- 每一个滤波器提取图像的某种特定特征，高层特征是低层特征的抽象与组合
- 使用PCA分解替代滤波器的学习过程
- 使用特征池化增强特征对形变的鲁棒性
- 结合CNN与PCANet的优势，在简化特征学习的同时保持CNN较为合理的网络结构

PCN-基于PCA的卷积神经网络

➤ 基于PCA的深度卷积网络

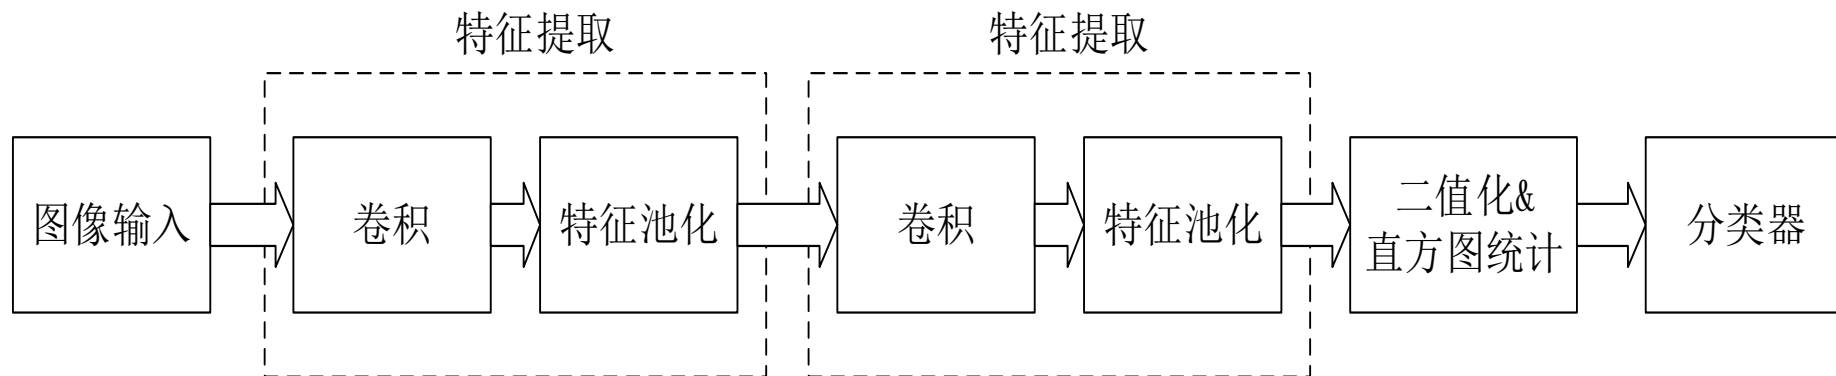
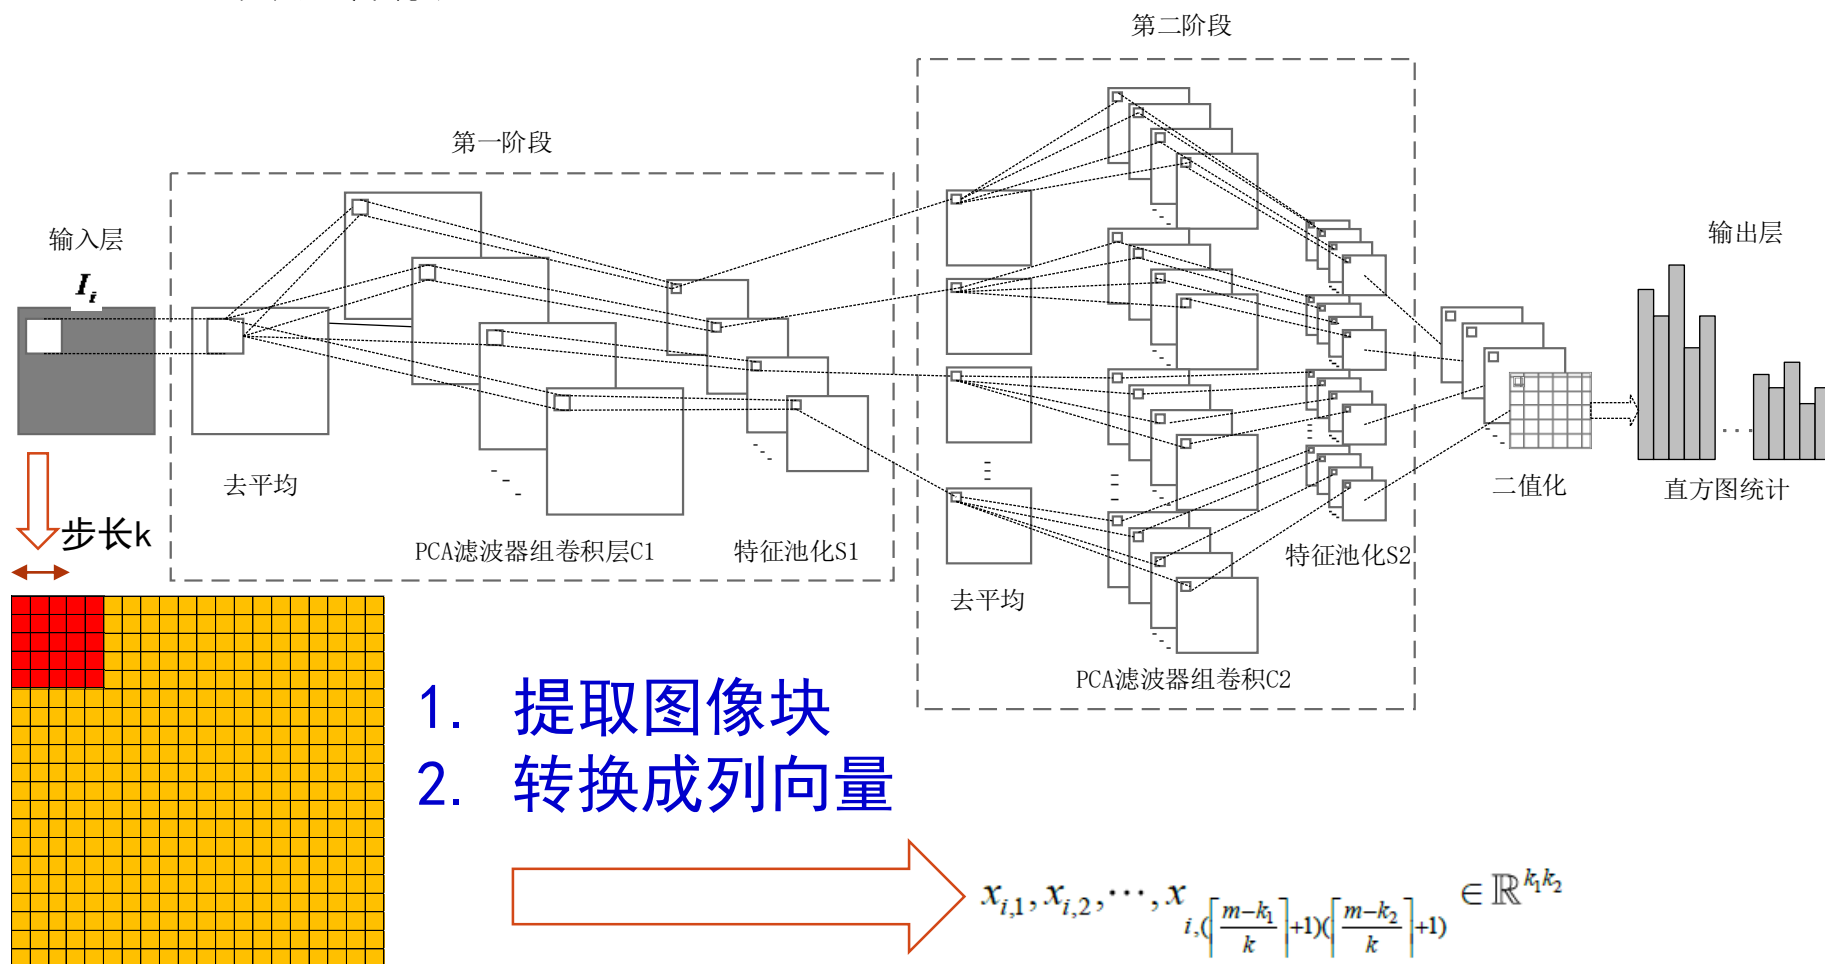



图6- 5 两阶段基于PCA滤波器的卷积网络算法框图

PCN-基于PCA的卷积神经网络

➤ PCN算法流程





过程纹理生成-纹理特征提取方法



第一阶段特征提取

1. 按列去平均
2. 图像块样本矩阵PCA分解
3. 选取前L1个特征向量，转换成L1个滤波器
4. 对原N幅输入图像与L1个滤波器分别卷积
5. 特征池化 (Pooling)





第*i*幅图像经过第*l*个滤波器卷积，池化后的特征图表示为 S_i^l

N幅图像经过第*l*个滤波器卷积，池化后的特征图表示为

$$\{S_i^l\}_1^N, \quad i=1,2,\dots,N, \quad l=1,2,\dots,L_1$$

过程纹理生成-纹理特征提取方法

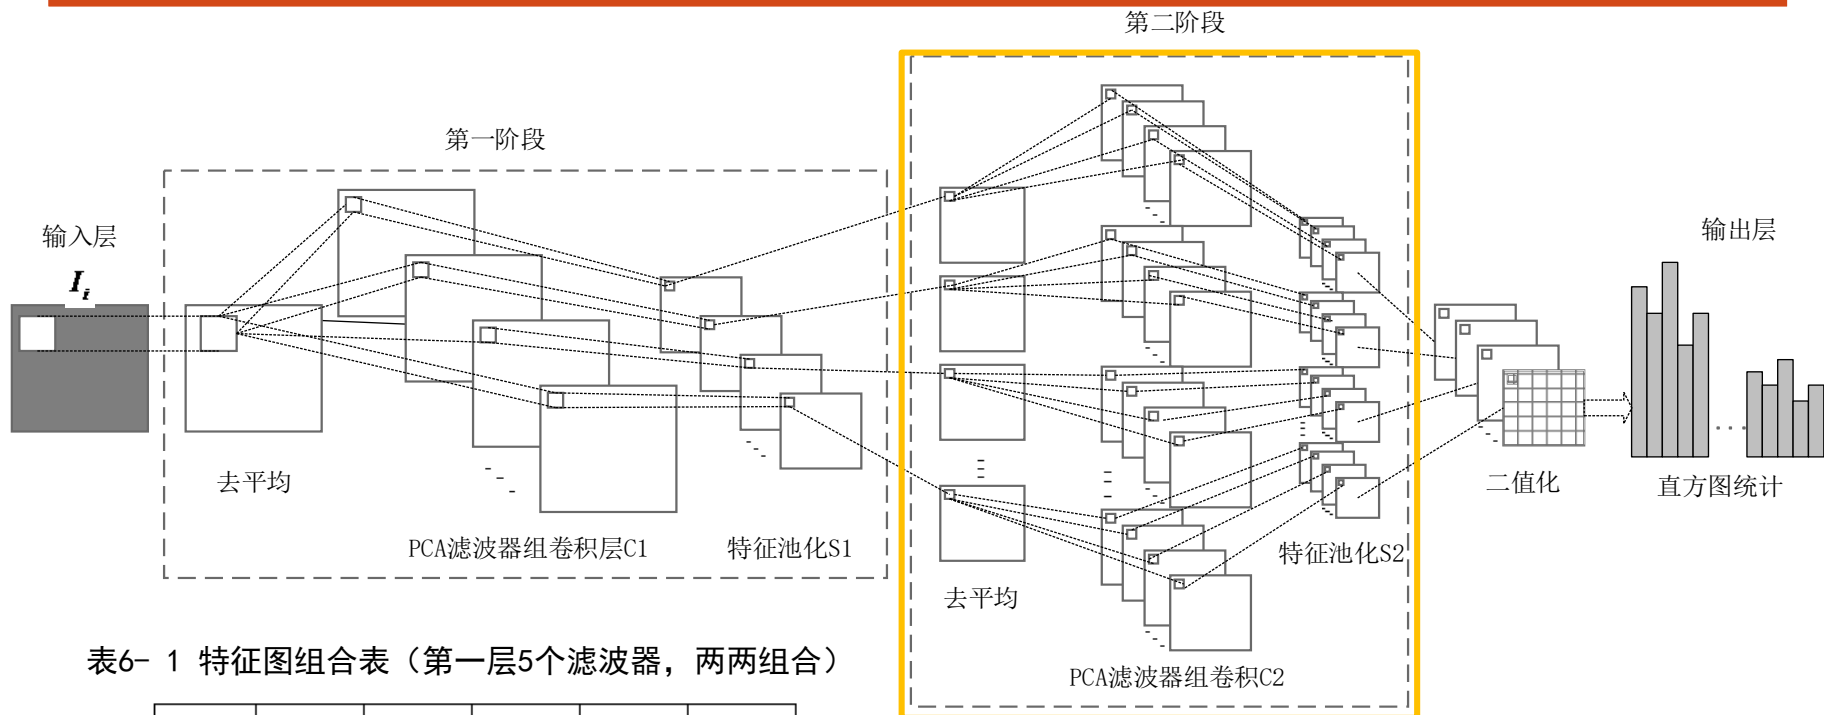



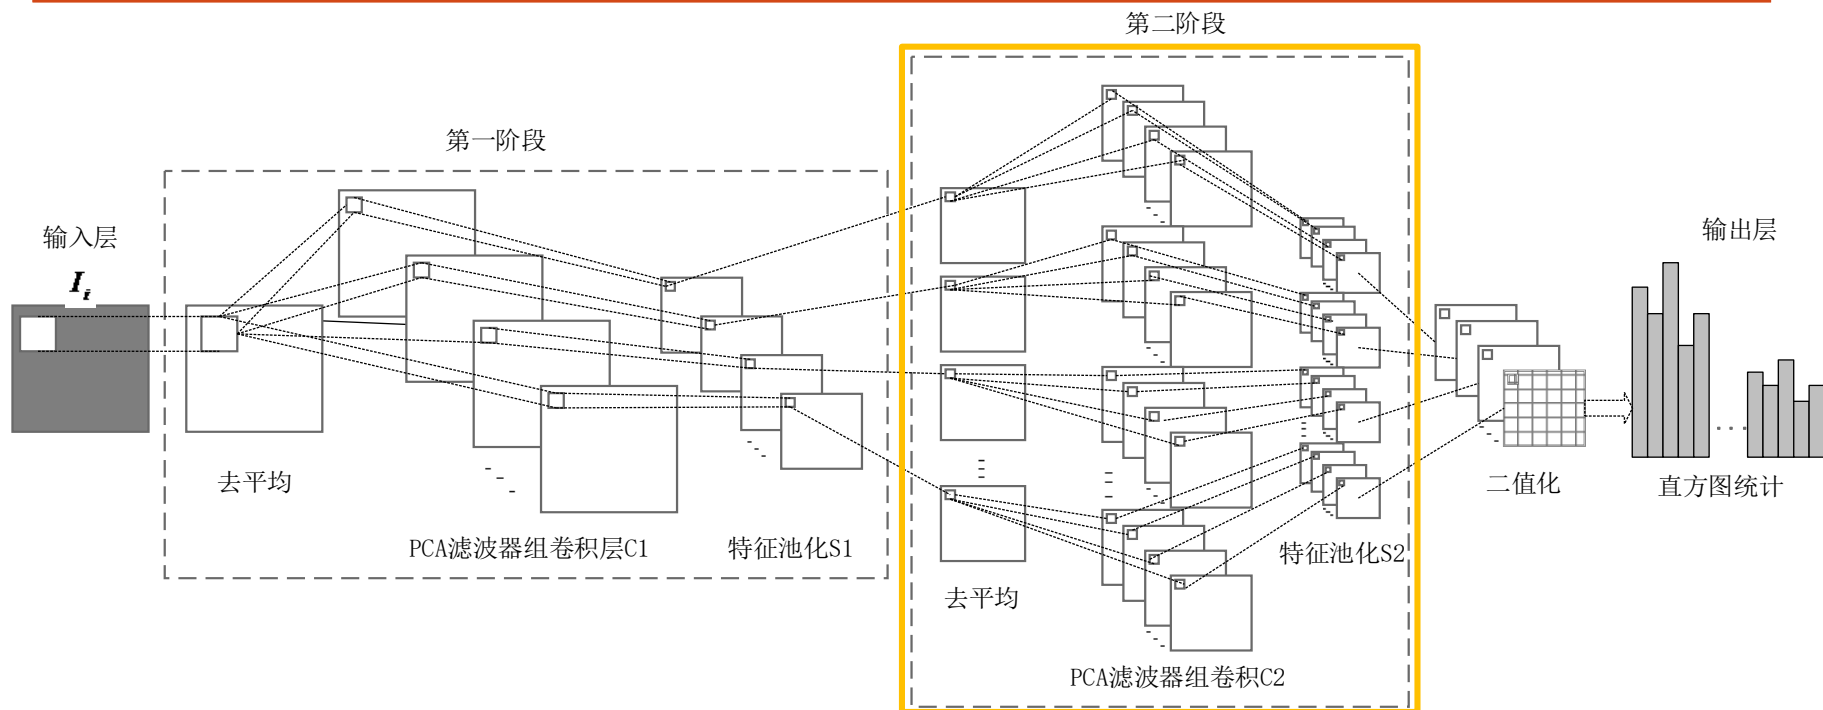
表6- 1 特征图组合表（第一层5个滤波器，两两组合）

	1	2	3	4	5
S^1	×				×
S^2	×	×			
S^3		×	×		
S^4			×	×	
S^5				×	×

第二阶段特征提取

1. 特征图组合
2. 重复第一阶段
 - 去平均
 - 卷积
 - 池化

过程纹理生成-纹理特征提取方法

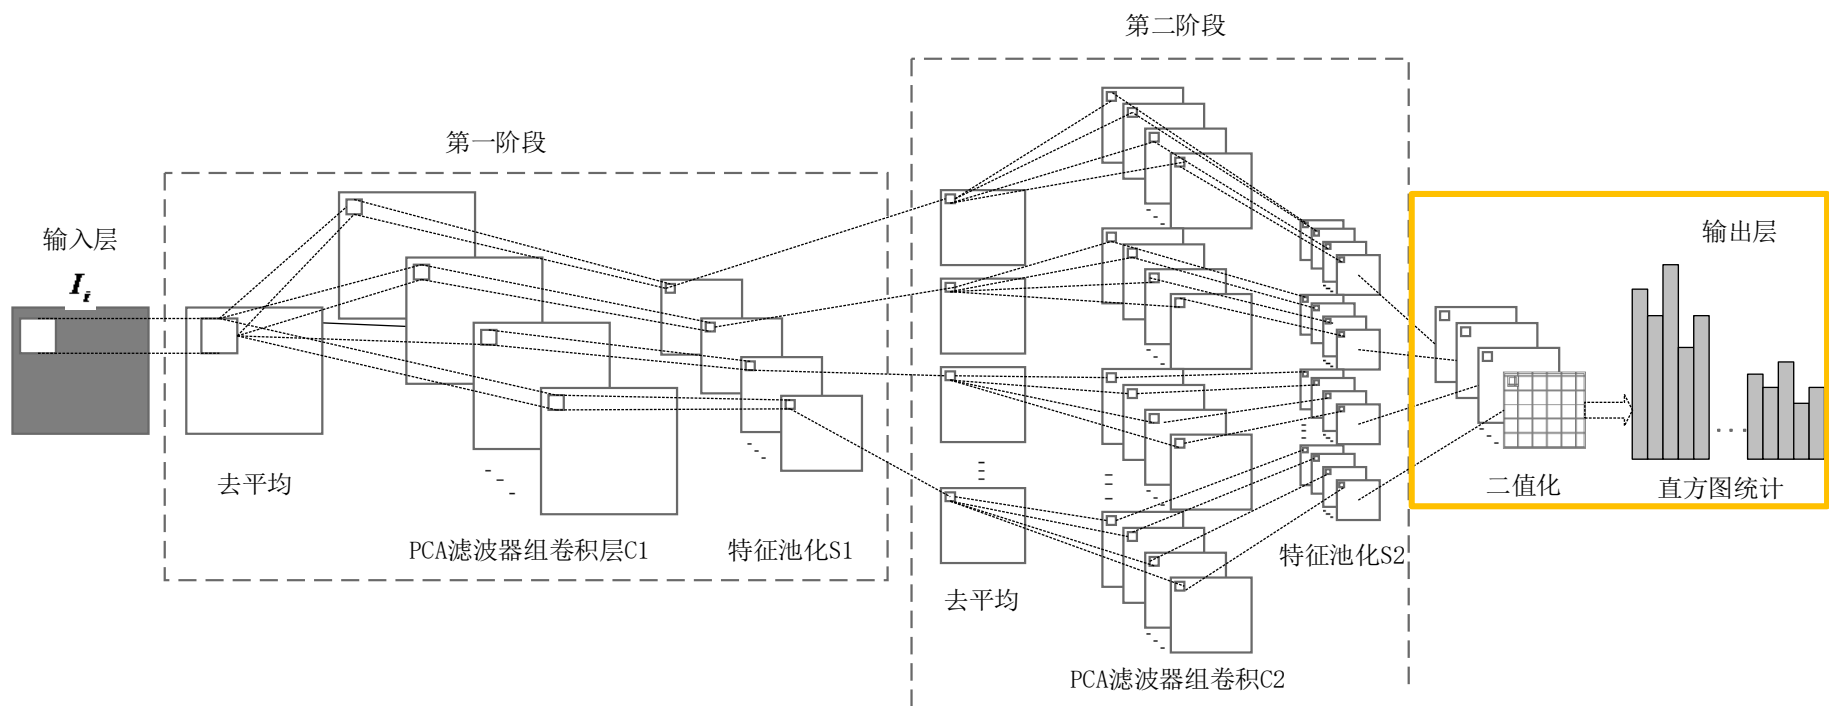


- 第二阶段特征提取

- 1. 特征图组合


- 经过第一阶段特征提取后共得到 $N \times L$ 个特征图输出,
 - 每个子集里面包含 N 幅特征图, 共有 L 个子集。
 - 每个子集里包含的特征图提取了特定的特征;
 - 不同的子集包含的特征图的特征是不同的
 - 组合后的特征图作为第二阶段的输入

- 2. 重复第一阶段特征提取过程



$$\{H(I_i^l * W_l^2)\}_{l=1}^{L_2} \Rightarrow T_i^l = \sum_{l=1}^{L_2} 2^{l-1} H(I_i^l * W_l^2) \Rightarrow$$

单位阶跃函数



$$f_i = [Bhist(T_i^1), \dots, Bhist(T_i^{L_1})]^T \in \mathbb{R}^{(2^{L_2})L_1B}$$

➤ 算法分析

- PCN卷积层中滤波器是通过PCA算法学习得到，滤波后的特征图像是相互独立的，不存在相关性
- PCN结构中的特征图组合采用了高层特征是低层特征的抽象与组合这一基本思想；高层学习出的滤波器能够提取出更加抽象和全局的特征
- 算法中的特征池化单元，使得学习出的特征具有一定的旋转不变性，而且减小了输出特征图的大小，加快了高层中PCA滤波器的学习速度
- 间隔采样图像块的策略，减小了数据的维数，加快学习速度

PCN-基于PCA的卷积神经网络 (PCA-based Convolutional Networks)

- 相关工作概况
- 卷积神经网络 (CNN)
- PCANet
- PCN的基本结构
- 部分实验
- 总结

➤ 实验结果及分析

实验一：手写数字识别测试

1. 基础Mnist数据库测试

算法	准确率 (%)
PCANet-2[170]	98.94
CAE-2[151]	97.52
ScatNet-2[158]	98.73
PCN-2	99.20

2. 标准Mnist数据库测试

算法	准确率 (%)
HSC[187]	99.23
KNN-SCM[188]	99.37
KNN-IDM[189]	99.46
CDBN[165]	99.18
ConvNet[157]	99.47
ScatNet-2[158]	99.57
PCANet-2[170]	99.34
PCN-2	99.41

➤ 实验结果及分析

实验二：Extended YaleB人脸识别测试



图6- 8 Extended Yale B中人脸图像示例

表6- 4 在Extended YaleB数据库上人脸识别准确率和时间比较

	PCANet-2	PCN-2
识别准确率 (%)	99.53	99.58
训练时间 (s)	8551	2054
每幅样本测试时间 (s)	1.39	0.27


➤ 实验结果及分析

实验三：纹理分类测试

CuRET纹理库测试

表6- 5 CURET纹理数据库分类准确率比较


方法	准确率 (%)
Texon[191]	98.50
BIF[192]	98.60
Histogram[193]	99.00
ScatNet-2[158]	99.80
PCANet-2[170]	99.61
PCN-2	99.71



实验四：过程纹理分类


➤ 过程纹理生成模型

- 广泛应用于计算机图形学中产生具有真实感的自然纹理
- 数学模型；模型参数难以控制
- 根据图像样本确定模型及参数
产生纹理具有具有重要的应用价值




➤ 纹理感知属性

重复性，随机性，粗糙度，方向性，结构复杂性，粗略度，规则性，均匀性……



方向性 = 2
粗糙
不规则

.....



方向性 = 5
均匀

.....

➤ 纹理图像的感知特征

分辨率高，图像尺度大

• 计算量大，空间复杂度高

结构复杂，变化范围大

• 手工特征难以表述

感知特征的取值具有主观性

• 具有挑战性的分类和预测问题

纹理图片平移旋转不改变感知特征

• 需要鲁棒性的特征提取算法

➤ 心理物理学实验

- 23种过程纹理生成模型产生450幅纹理高度图
- 光线追踪算法进行渲染——类似于三维自然纹理表面
- 心理物理学实验
 - 自由分组——获得纹理相似性矩阵
 - 感知评分——获得感知量化值



➤ 实验样本获取

- 更换光照条件，对高度图重新渲染得到450幅纹理图像，使其与心理物理学实验样本具有相同的感知特征
- 把每一幅纹理图像裁切成不重叠的4块图像
- 可得到具有感知数据的3600幅纹理图像（ 256×256 ）
- 可以采用其他方式继续增大训练样本

PCN-基于PCA的卷积神经网络

实验一：纹理数据库生成方法分类

方法	准确率（%）
PCANet-2	99.62
PCN-2	99.89

实验二：根据纹理图像预测感知特征

感知特征	准确率（%）
对比度	99.78
重复性	99.67
颗粒度	99.22
随机性	99.22
粗糙度	99.78
特征密度	99.56
方向性	99.78
结构复杂性	99.44
粗略度	99.44
规则性	99.67
局部方向一致性	99.78
均匀性	99.22

- 传统深度学习算法拥有较高的时间和空间复杂度
- PCANet通过更改滤波器的学习过程，降低了网络的时间复杂度，但是对滤波器的学习没有体现高层特征对底层特征的组合
- PCN完整保持了CNN的网络结构，包括特征组合和特征池化，通过更改滤波器的学习过程降低网络的时间复杂度，通过分批训练降低网络的空间复杂度
- 实验证明PCN拥有良好的性能和效率，在众多问题上具有通用性，且较好地解决了我们在纹理研究中的问题

- 简单、高效的网络结构
- 能够取得state-of-the-art的效果
- 论文链接: <http://arxiv.org/abs/1505.03703>
- 代码链接:
https://github.com/gyh5421/PCN_demo_saveTime/

感谢合作者: 甘言海、刘君、仲国强

Thank You